

שאלה 1:

הגדרנו זוג פונקציות עזר, אחת שמטרתה לייצר דגימות כפי שהוגדר בשם `generate_points` והשניה אשר מגדירה מסווג K-NN.

הפונקציות:

File - C:\Users\shado\PycharmProjects\Machine Learning 1\HW1\GenerateSamples.py

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3
4
5 def generate_samples(num, isplot):
6     """
7     Generating samples. A random number in [0,1]
8     chooses which mu-parameter we'll use for the normal
9     distribution.
10    :param num: number of samples we want to generate
11    :param isplot: if isplot == 1, it will plot all
12    the samples generated as dots.
13    else it will not plot it.
14    :return: a list of size 2, when index 0 contains
15    all the samples, and index 1 contains all their
16    labels.
17    """
18    mu1 = [-1, 1]
19    mu2 = [-2.5, 2.5]
20    mu3 = [-4.5, 4.5]
21    sigma = [[1, 0], [0, 1]]
22    test_group = []
23    test_group_labels = []
24    for i in range(num):
25        pickmu = np.random.rand()
26        if pickmu < 1 / 3:
27            mean = mu1
28            label = 1
29        elif pickmu > 2 / 3:
30            mean = mu3
31            label = 3
32        else:
33            mean = mu2
34            label = 2
35
36        test_group.append(np.random.
37            multivariate_normal(mean, sigma))
38        test_group_labels.append(label)
39    if isplot == 1:
40        fig, ax = plt.subplots()
```

```

1 from sklearn.neighbors import KNeighborsClassifier
2
3
4 def knnexec(k, trainset, testset, is_train):
5     """
6     Create a K-NN classifier, using the train set,
7     and predicts the test set or the train set.
8     :param k: parameter K in the K-NN classifier
9     :param trainset: A list of size two. index 0
10    contain all the train samples, and index 1 contains
11    all their labels.
12    :param testset: A list of size two. index 0
13    contain all the test samples, and index 1 contains
14    all their labels.
15    :param is_train: If is_train == 1, the function
16    will try to predict the train samples labels.
17    else, it will predict the test samples labels.
18    :return: the error rate of prediction as
19    mentioned in the assignment.
20    """
21    test_size = len(testset[0])
22    train_size = len(trainset[0])
23    classifier = KNeighborsClassifier(n_neighbors=k)
24    classifier.fit(trainset[0], trainset[1])
25    error = 0
26    if is_train == 1:
27        pred = classifier.predict(trainset[0])
28        for i in range(train_size):
29            if pred[i] != trainset[1][i]:
30                error += 1
31        return error / train_size
32    else:
33        pred = classifier.predict(testset[0])
34        for i in range(test_size):
35            if pred[i] != testset[1][i]:
36                error += 1
37        return error / test_size
38
39

```

לאחר מכן, הגדרנו פונקציות אשר עונות על כל השאלות בנפרד.


סעיפים 1-4:

הפונקציה:


```
1 from GenerateSamples import generate_samples
2 from knnexec import knnexec
3
4
5 def question1to4():
6     train_set = generate_samples(700, 1)
7     test_set = generate_samples(300, 1)
8     train_error = knnexec(1, train_set, test_set, 1)
9     test_error = knnexec(1, train_set, test_set, 0)
10    print(train_error)
11    print(test_error)
```

הגרפים שהתקבלו:

Test Set



Train Set



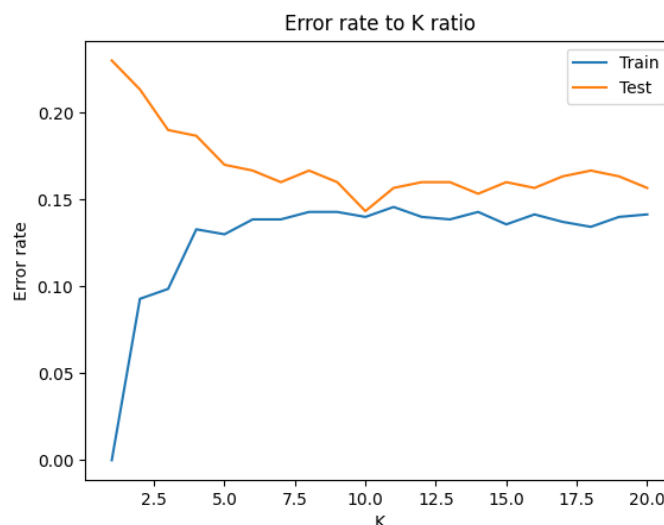
תשובה לסעיף 4: Error rate שהתקבל כשניסינו לצפות את Train Set היה 0, כפי שציפינו, משום שמסווג 1-NN יסווג נקודה מסט האימון לפי השכן הכי קרוב שלה – והיא תמיד תהייה הנקודה עצמה. לכן הוא תמיד יסווג נכון. מנגד, קיבלנו שגיאה של 19.6% על Test Set וזה בגלל שמסווג אשר בודק רק את השכן האחד הכי קרוב, לא מדויק, היות והוא סובל מ-Overfitting.

סעיף 5:

הפונקציה שבה השתמשנו:

```
1 from GenerateSamples import generate_samples
2 from knnexec import knnexec
3 import matplotlib.pyplot as plt
4
5
6 def question5():
7     train_set = generate_samples(700, 0)
8     test_set = generate_samples(300, 0)
9     error_on_train_set = []
10    error_on_test_set = []
11    ax = [i for i in range(1, 21)]
12    for i in range(1, 21):
13        error_on_train_set.append(knnexec(i,
14    train_set, test_set, 1))
15        error_on_test_set.append(knnexec(i, train_set
16    , test_set, 0))
17    plt.plot(ax, error_on_train_set, label="Train")
18    plt.plot(ax, error_on_test_set, label="Test")
19    plt.xlabel("K")
20    plt.ylabel("Error rate")
21    plt.title("Error rate to K ratio")
22    plt.legend()
23    plt.show()
```

והגרף שהתקבל הינו:



תשובה לסעיף 5: ניתן לראות כי השגיאה קטנה ככל ש-K גדל. אנחנו גם רואים מהגרף, שזה לא תמיד מתקיים, כפי שניתן לראות על פי השיפועים החיוביים בגרף הכתום. דוגמא נגדית נוספת תהייה:

נסווג נקודות על המישור הקרטזי, כך שהליבלים הם שחור או לבן.

$train\ set = \{(1,0, Black), (0,1, black), (0,0, White)\}$

$test\ set = \{(0,0.1, White)\}$

עבור $K=1$ המסווג יסווג נכון, היות והנקודה הכי קרובה לנק' הנבדקת היא הנקודה הלבנה בראשית הצירים.

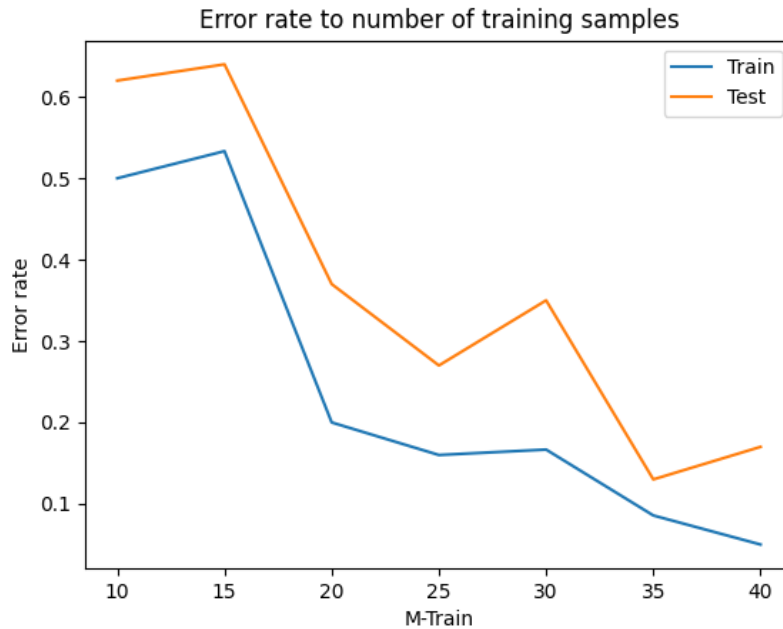
כאשר $K=3$ המסווג יסווג כשחור, היות ואלו יהיו רוב השכנים של הנק' הנבדקת. דבר כזה קורה בדרך כלל כאשר K גדול מאוד, ביחס לגודל של סט האימון.

סעיף 6:

הפונקציה:

```
1 from GenerateSamples import generate_samples
2 from knnexec import knnexec
3 import matplotlib.pyplot as plt
4
5
6 def question6():
7     m_train = [i for i in range(10, 45, 5)]
8     m_test = 100
9     k = 10
10    error_rate_train = []
11    error_rate_test = []
12    for m in m_train:
13        train_set = generate_samples(m, 0)
14        test_set = generate_samples(m_test, 0)
15        error_rate_train.append(knnexec(k, train_set
16    , test_set, 1))
17        error_rate_test.append(knnexec(k, train_set,
18    test_set, 0))
19    plt.plot(m_train, error_rate_train, label="Train"
20    )
21    plt.plot(m_train, error_rate_test, label="Test")
22    plt.xlabel("M-Train")
23    plt.ylabel("Error rate")
24    plt.title("Error rate to number of training
25    samples")
26    plt.legend()
27    plt.show()
```

הגרף המתקבל:



תשובה לסעיף 5: כאשר $K=10$ נוצרת אותה הבעיה שראינו בסעיף 5, כאשר אין לנו מספיק דוגמאות בסט האימון שלנו יחסית לגודל של K . אנחנו מאמינים שכלל שסט האימון יכול יותר דוגמאות, הטעות תרד.

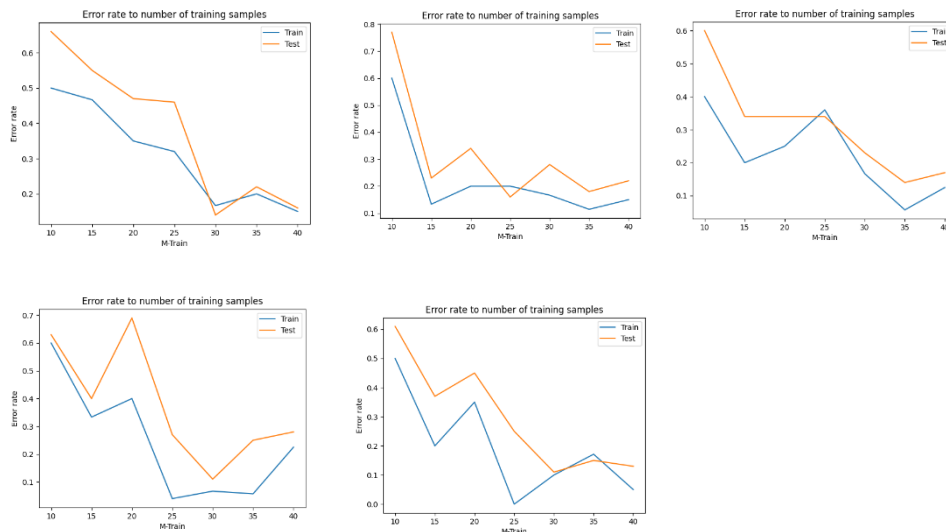
לאחר שהבטנו בגרף, אנו רואים שזה לא תמיד המקרה. באופן כללי, קיימת מגמת ירידה גם לסט האימון וגם לסט המבחן, אך לא לכל איטרציה בה כמות הדוגמאות שלנו גדלה.

סעיף 7:

הפונקציה:

```
1 def question7():
2     for i in range(6):
3         question6()
```

הגרפים שהתקבלו:



תשובה לסעיף 7: הגרפים משתנים בצורה דרסטית בכל הרצה של הפונקציה מסעיף 6, אך באופן כללי השגיאה נהיית קטנה יותר בכולם ככל שסט האימון גדל.

השינויים הבולטים יכולים להיות מוסברים על ידי הרנדומליות איתה יצרנו את סט האימון והמבחן שלנו. כיוון שבאו מפונקציה הסתברותית, ככל שיש פחות נקודות ההבדלים ביניהם מאוד גדולים. אם היינו מייצרים כמות גדולה מאוד של נקודות, הגרפים היו "מתמצעים" לפחות או יותר אותם הערכים לפי פונקציות ההסתברותיות בהן השתמשנו.

סעיף 8:

נציע מסווג K-NN אשר עבור כל נקודה שהוא אמור לסווג, הוא לוקח את קבוצת השכנים שלו, ומחלק אותה למחלקות, כך שכל מחלקה שייכת ללייבל אחר. לאחר מכן הוא לוקח את המרחק האוקלידי הממוצע של הנקודות במחלקה מסויימת מהנקודה הנבדקת. המחלקה שהמרחק הממוצע ממנה, אל הנקודה הנבדקת, הוא הקטן ביותר, תהייה הלייבל של הנק' הנבדקת.

3 ml

1. $y_i \in [1, \dots, k]$ and the Col $S = \{(x_i, y_i), i=1, \dots, m\}$ will be \rightarrow

$$p_w(Y_i = k | X_i) = \frac{e^{w^T_k X_i}}{\sum_{j=1}^K e^{w^T_j X_i}} = p^k$$

בהקדמה הבינארית כלשהי $y \in \{0,1\}^*$:

$$p_w(Y_i = 1 | X_i) = \frac{e^{w_k^T X_i}}{1 + e^{w_k^T X_i}} = p$$

לצדד פוקצ'ה (γ, x) שלבחה פוקצ'ה יהיה γ כן. לעבור חקרה
 הביא- $\gamma \in [0, 1]$ ויהיה $\gamma = 1$ לקרא שלבחה חקרה γ חקרה
 פוקצ'ה חקרה חקרה.

$$\phi(x,y) = \begin{cases} x & , y=1 \\ 0 & , \text{onk} \end{cases}$$

$$p(y=1/x, w) = \frac{e^{w^T \phi(x, 1)}}{e^{w^T \phi(x, 1)} + e^{w^T \phi(x, 0)}} = \frac{e^{w^T x}}{e^{w^T x} + e^{w^T 0}} = \frac{e^{w^T x}}{e^{w^T x} + 1} = p_1$$

$$p(y=0/x, w) = \frac{e^{w^T \phi(x, 0)}}{e^{w^T \phi(x, 1)} + e^{w^T \phi(x, 0)}} = \frac{e^{w^T x}}{e^{w^T x} + e^{w^T 0}} = \frac{1}{e^{w^T x} + 1} = p_2$$

$$p_1 + p_2 = \frac{e^{w^T x}}{e^{w^T x} + 1} + \frac{1}{e^{w^T x} + 1} = 1$$

2.

$$W^* = \operatorname{argmax}_w \left[\sum_{i=1}^m \log(p_w(Y_i = k / X_i)) \right]$$

moment matching constraint זה לא כלליל ו'

 המכונה לא המזהה ה'.

$$p(Y_i = k / X_i) = \frac{e^{w_k^T X_i}}{\sum_k e^{w_k^T X_i}} \quad \text{: כדי למצוא מקסימום}$$

הנקודה - log likelihood וזהו i נקודה:

$$\log(p(Y_i = k / X_i)) = \log\left(\frac{e^{w_k^T X_i}}{\sum_k e^{w_k^T X_i}}\right) = w_k^T X_i - \log\left(\sum_k e^{w_k^T X_i}\right)$$

אם p, w הם כלליל, המכונה המקסימום לא נקודה,

 : $L_s(w)$ נקודה

$$L_s(w) = \frac{1}{m} \sum_{i=1}^m \log(p(Y_i = y_i / X_i)) = \frac{1}{m} \sum_{i=1}^m \left(\log\left(\sum_k e^{w_k^T X_i}\right) - w_{y_i}^T X_i \right)$$

זהו לא המזהה $L_s(w)$ זהו w וזהו 0 :

$$\forall k = 1, \dots, K : \frac{\partial L_s(w)}{\partial w_k} = \sum_{i=1}^m I[Y_i = k] X_i - \sum_{i=1}^m \left(\frac{e^{w_k^T X_i}}{\sum_k e^{w_k^T X_i}} \right) X_i$$

$$\sum_{i=1}^m I[Y_i = k] X_i = \sum_{i=1}^m \left(\frac{e^{w_k^T X_i}}{\sum_k e^{w_k^T X_i}} \right) X_i$$

↓

 : moment matching constraint זהו

$$\forall k = 1, \dots, K \quad \sum_{i=1}^m I[Y_i = k] X_i = \sum_{i=1}^m \left(\frac{e^{w_k^T X_i}}{\sum_k e^{w_k^T X_i}} \right) X_i$$

: $L_s(w)$ המכונה w^* זהו המקסימום

$$\forall k = 1, \dots, K \quad \sum_{i=1}^m I[Y_i = k] X_i = \sum_{i=1}^m \left(\frac{e^{w_k^T X_i}}{\sum_k e^{w_k^T X_i}} \right) X_i = \sum_{i=1}^m (p_w(Y_i = k / X_i)) X_i$$

← זהו המכונה

3. א. ב. אלו 3 מרחקים ממוצא לא נמצאים באלמנט המאפיין, אלא אלו
 שיש להם הסתברות מסוימת של להיות 0 או 1.

ב.

$$h_s(x_i) = w_1 x_{i1} + w_2 x_{i2} + \dots + w_d x_{id} + b = w^T x_i + b$$

כאשר b ממוצא לא נמצא באלמנט המאפיין (bias).

אם p , אפשר להחזיר לכל ערך במרחב המאפיין (0-1) ערך

$$\tilde{x}_i = (1, x_i) \quad \rightarrow 1$$

נקודה:

$$h_s(x_i) = w_0 x_{i0} + w_1 x_{i1} + \dots + w_d x_{id} = w^T \tilde{x}_i$$

$$w_0 = b \quad \text{מכאן}$$



הערכות המקוריות $x_i \in \mathbb{R}^d$ נמצאות באלמנט המאפיין, $w \in \mathbb{R}^{d+1}$, p זה המקור

$$\underline{w \in \mathbb{R}^3 \text{ נמצא } x \in \mathbb{R}^2 \iff x' = (1, x)}$$

$$x_i = (x_{i0}, x_{i1}, x_{i2}) = (1, 1, 8) \quad \text{ז.}$$

$$p_w(Y=0/x_1) = \frac{e^{w_1^T x_1}}{e^{w_1^T x_1} + e^{w_2^T x_1} + e^{w_3^T x_1}} = \frac{e^{21.5}}{e^{21.5} + e^{-9.5} + e^{-12}} \approx 1$$

$$p_w(Y=1/x_1) = \frac{e^{w_2^T x_1}}{e^{w_1^T x_1} + e^{w_2^T x_1} + e^{w_3^T x_1}} = \frac{e^{-9.5}}{e^{21.5} + e^{-9.5} + e^{-12}} = 3.44 \times 10^{-14} \approx 0$$

$$p_w(Y=2/x_1) = \frac{e^{w_3^T x_1}}{e^{w_1^T x_1} + e^{w_2^T x_1} + e^{w_3^T x_1}} = \frac{e^{-12}}{e^{21.5} + e^{-9.5} + e^{-12}} = 2.826 \times 10^{-15} \approx 0$$

החישובים בהם השלשון:

$$\begin{aligned} w_1^T x_1 &= (8, -2.5, 2) \begin{pmatrix} 1 \\ 1 \\ 8 \end{pmatrix} = 8 - 2.5 + 16 = 21.5 \\ w_2^T x_1 &= (2, 0.5, -1.5) \begin{pmatrix} 1 \\ 1 \\ 8 \end{pmatrix} = 2 + 0.5 - 12 = -9.5 \\ w_3^T x_1 &= (-10, 2, -0.5) \begin{pmatrix} 1 \\ 1 \\ 8 \end{pmatrix} = -10 + 2 - 4 = -12 \end{aligned}$$

מסקנה: המוגד יסודי \rightarrow העיבוד של $x_1 \Rightarrow 0$.

$$x_2 = (x_{i0}, x_{i1}, x_{i2}) = (1, 6, -2)$$

$$p_w(Y=0/x_2) = \frac{e^{w_1^T x_2}}{e^{w_1^T x_2} + e^{w_2^T x_2} + e^{w_3^T x_2}} = \frac{e^{-11}}{e^{-11} + e^8 + e^3} = 5.56 \times 10^{-9} \approx 0$$

$$p_w(Y=1/x_2) = \frac{e^{w_2^T x_2}}{e^{w_1^T x_2} + e^{w_2^T x_2} + e^{w_3^T x_2}} = \frac{e^8}{e^{-11} + e^8 + e^3} = 0.993$$

$$p_w(Y=2/x_2) = \frac{e^{w_3^T x_2}}{e^{w_1^T x_2} + e^{w_2^T x_2} + e^{w_3^T x_2}} = \frac{e^3}{e^{-11} + e^8 + e^3} = 6.61 \times 10^{-3}$$

החישובים בהם השלשון:

$$\begin{aligned} w_1^T x_2 &= (8, -2.5, 2) \begin{pmatrix} 1 \\ 6 \\ -2 \end{pmatrix} = 8 - 15 - 4 = -11 \\ w_2^T x_2 &= (2, 0.5, -1.5) \begin{pmatrix} 1 \\ 6 \\ -2 \end{pmatrix} = 2 + 3 + 3 = 8 \\ w_3^T x_2 &= (-10, 2, -0.5) \begin{pmatrix} 1 \\ 6 \\ -2 \end{pmatrix} = -10 + 12 + 1 = 3 \end{aligned}$$

מסקנה: המוגד יסודי \rightarrow העיבוד של $x_2 \Rightarrow 1$.

$$X_3 = (X_{i0}, X_{i1}, X_{i2}) = (1 \ 12 \ 4)$$

$$p_w(Y=0/X_3) = \frac{e^{w_1^T X_3}}{e^{w_1^T X_3} + e^{w_2^T X_3} + e^{w_3^T X_3}} = \frac{e^{-14}}{e^{-14} + e^2 + e^{12}} = 5.1 \times 10^{-12}$$

$$p_w(Y=1/X_3) = \frac{e^{w_2^T X_3}}{e^{w_1^T X_3} + e^{w_2^T X_3} + e^{w_3^T X_3}} = \frac{e^2}{e^{-14} + e^2 + e^{12}} = 4.54 \times 10^{-5}$$

$$p_w(Y=2/X_3) = \frac{e^{w_3^T X_3}}{e^{w_1^T X_3} + e^{w_2^T X_3} + e^{w_3^T X_3}} = \frac{e^{12}}{e^{-14} + e^2 + e^{12}} = 0.99$$

החישובים בקדם השלשון:

$$\begin{aligned} w_1^T X_3 &= (8 \ -2.5 \ 2) \begin{pmatrix} 1 \\ 12 \\ 4 \end{pmatrix} = 8 - 30 + 8 = -14 \\ w_2^T X_3 &= (2 \ 0.5 \ -1.5) \begin{pmatrix} 1 \\ 12 \\ 4 \end{pmatrix} = 2 + 6 - 6 = 2 \\ w_3^T X_3 &= (-10 \ 2 \ -0.5) \begin{pmatrix} 1 \\ 12 \\ 4 \end{pmatrix} = -10 + 24 - 2 = 12 \end{aligned}$$

מסקנה: המודל יסווג את העיגול של X_3 כ-2.