

**תרגיל בית 4 – למידה**

**חישובית 1**

**096411**

שמות המגישים:

רוני פרידמן, ת.ז: 205517097

מור לוינבוק, ת.ז: 205451123

## שאלה 1:

א.  $S^{(i)}$  – קבוצת כל הדוגמאות מסט האימון, כאשר החלפנו את הדוגמא  $(x_i, y_i)$  בדוגמא  $(x', y')$ .  
 $A(S)$  – ההיפוטזה (כלל ההחלטה) שהאלגוריתם  $A$  החזיר לנו על ידי מציאת המינימום של  $f_S(w)$  עבור סט האימון  $S$  הנתון.

ב.

$$\begin{aligned} f_S(v) &= L_S(v) + \lambda \|v\|_2^2 = \frac{1}{m} \sum_{i=1}^m l(v, x_i, y_i) + \lambda \|v\|_2^2 = \\ &= \frac{1}{m} \left( \left( \sum_{i=1}^{i-1} l(v, x_i, y_i) \right) + l(v, x', y') + \left( \sum_{i=i+1}^m l(v, x_i, y_i) \right) - l(v, x', y') + l(v, x_i, y_i) \right) + \lambda \|v\|_2^2 = \\ &= \frac{1}{m} \left( L_{S^{(i)}}(v) - l(v, x', y') + l(v, x_i, y_i) \right) + \lambda \|v\|_2^2 = \frac{1}{m} L_{S^{(i)}}(v) + \lambda \|v\|_2^2 + \frac{l(v, x_i, y_i) - l(v, x', y')}{m} \end{aligned}$$

לכן מתקיים:

$$\begin{aligned} f_S(v) - f_S(u) &= \frac{1}{m} L_{S^{(i)}}(v) + \lambda \|v\|_2^2 + \frac{l(v, x_i, y_i) - l(v, x', y')}{m} \\ &\quad - \left( \frac{1}{m} L_{S^{(i)}}(u) + \lambda \|u\|_2^2 + \frac{l(u, x_i, y_i) - l(u, x', y')}{m} \right) = \\ &= \left( \frac{1}{m} L_{S^{(i)}}(v) + \lambda \|v\|_2^2 \right) - \left( \frac{1}{m} L_{S^{(i)}}(u) + \lambda \|u\|_2^2 \right) + \frac{l(v, x_i, y_i) - l(u, x_i, y_i)}{m} + \frac{l(u, x', y') - l(v, x', y')}{m} \end{aligned}$$

כנדרש.

ג. מסעיף ב' מתקיים:

$$\begin{aligned} f_S(A(S^{(i)})) - f_S(A(S)) &= \frac{1}{m} L_{S^{(i)}}(A(S^{(i)})) - \frac{1}{m} L_{S^{(i)}}(A(S)) + \frac{l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i)}{m} + \\ &\quad + \frac{l(A(S), x', y') - l(A(S^{(i)}), x', y')}{m} \end{aligned}$$

אנו יודעים כי:

$$\frac{1}{m} L_{S^{(i)}}(A(S^{(i)})) \leq \frac{1}{m} L_{S^{(i)}}(A(S))$$

וזאת כי  $A$  מחזיר לנו את המינימום על ממוצע הloss של סט האימון הנבדק. כלומר ההיפוטזה  $A(S^{(i)})$  מביאה לנו את המינימום על  $L_{S^{(i)}}$  ולכן ממוצע הloss שמתקבל על ידי ההיפוטזה  $A(S)$  יכול רק לגדול.

אם כך, מתקיים:

$$f_S(A(S^{(i)})) - f_S(A(S)) \leq \frac{l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i)}{m} + \frac{l(A(S), x', y') - l(A(S^{(i)}), x', y')}{m}$$

ד. אנו יודעים כי הפונקציה  $g(w) = \lambda \|w\|^2$  היא קמורה חזק בדרגה  $2\lambda$ .

בנוסף אנו יודעים כי הפונקציה  $h(S, w) = \frac{1}{m} L_S(w)$  היא קמורה.

ממשפט, אנו יודעים כי הפונקציה  $f(S, w) = h(S, w) + g(w)$  גם היא קמורה חזק בדרגה  $2\lambda$ .

לפי משפט, אנו יודעים כי בהנתן  $S$ , ובגלל ש  $f$  קמורה חזק בדרגה  $2\lambda$ , עבור  $u$  שממזער את  $f$  מתקיים:

$$f(S, w) - f(S, u) \geq \frac{2\lambda}{2} \|w - u\|^2 = \lambda \|w - u\|^2$$

לכל  $w$ .

נציב  $u = A(S)$ ,  $w = A(S^{(i)})$  ונקבל:

$$\lambda \|A(S^{(i)}) - A(S)\|^2 = \lambda \|A(S) - A(S^{(i)})\|^2 \leq f_S(A(S^{(i)})) - f_S(A(S))$$

היות ו  $A(S)$  הממזער של הפונק'  $f_S$ .

טענה זו בשילוב עם סעיף ג' נותנת לנו:

$$\lambda \|A(S^{(i)}) - A(S)\|^2 \leq \frac{l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i)}{m} + \frac{l(A(S), x', y') - l(A(S^{(i)}), x', y')}{m}$$

ה. נניח כי פונק'  $loss$  היא  $\rho$  ליפשיצית. מעובדה זו, ומחוקי הערך המוחלט, בהנתן  $(x, y)$ :

$$l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i) \leq |l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i)| \leq \rho \|A(S^{(i)}) - A(S)\|$$

באופן דומה:

$$l(A(S), x', y') - l(A(S^{(i)}), x', y') \leq |l(A(S), x', y') - l(A(S^{(i)}), x', y')| \leq \rho \|A(S^{(i)}) - A(S)\|$$

נציב באי השיוויון שמצאנו בסעיף ד':

$$\lambda \|A(S^{(i)}) - A(S)\|^2 \leq \frac{\rho \|A(S^{(i)}) - A(S)\|}{m} + \frac{\rho \|A(S^{(i)}) - A(S)\|}{m} = \frac{2\rho \|A(S^{(i)}) - A(S)\|}{m}$$

עבור המקרה בו  $A(S^{(i)}) = A(S)$  קל לראות כי מתקיים שוויון  $0=0$  בין האגפים.

במקרה כי הם שונים, מתקבל:

$$\|A(S^{(i)}) - A(S)\| \leq \frac{2\rho}{\lambda m}$$

ו. כפי שהראנו בסעיף ה':

$$l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i) \leq |l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i)| \leq \rho \|A(S^{(i)}) - A(S)\|$$

ולפי המסקנה שהוכחנו בסעיף ה':

$$l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i) \leq \rho \|A(S^{(i)}) - A(S)\| \leq \frac{2\rho^2}{\lambda m}$$

ז.  $L_S(w) -$  השגיאה האמפירית. זהו ממוצע השגיאות (שמוגדרות על ידי פונקצ' ה- $loss$ ) שההיפוטזה  $w$  ביצעה

על סט האימון  $S$ . בהנתן סט אימון  $S$  ו- $w$ , ניתן לחשב את ערך הביטוי, אם נגדיר את פונק'  $loss$  אז כל הנתונים

לחישוב הביטוי יהיה ברשותנו.

$L_D(w) -$  תוחלת השגיאה על כל הדוגמאות שהגיעו מהתפלגות  $D$ . זוהי תוחלת השגיאות שהמסווג שלנו יבצע

על כל דוגמא שאי פעם הגיעה או תגיע מהתפלגות  $D$ . כמובן, שלא ניתן לחשב את ביטוי זה בהנתן סט אימון  $S$

והיפוטזה  $w$ , כיוון שסט האימון הוא רק מדגם מייצג, ובשביל לחשב את  $L_D$  במדויק נצטרך או לעבור על כל

הדוגמאות בהסטוריה, או לדעת במפורש מהיא התפלגות  $D$  – שני מאורעות שיקרו בהסתברות אפסית גם אם ממש נתאמץ.

ח. לפי המשפט שנלמד בהרצאה (מצגת 6 שקף 18):

$$\mathbb{E}_{S \sim D^m} [L_D(A(S)) - L_S(A(S))] = \mathbb{E}_{(S, z') \sim D^{m+1}, i \sim U(m)} [l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i)]$$

ולפי סעיף ו' מתקיים:

$$\mathbb{E}_{(S, z') \sim D^{m+1}, i \sim U(m)} [l(A(S^{(i)}), x_i, y_i) - l(A(S), x_i, y_i)] \leq \mathbb{E}_{(S, z') \sim D^{m+1}, i \sim U(m)} \left[ \frac{2\rho^2}{\lambda m} \right] = \frac{2\rho^2}{\lambda m}$$

היות ואין לנו משתנים מקריים יותר בתוך ביטויי התוחלת. אם כך מתקיים:

$$\mathbb{E}_{S \sim D^m} [L_D(A(S)) - L_S(A(S))] \leq \frac{2\rho^2}{\lambda m}$$

## שאלה 2:

א.

$$recall = \frac{TP}{TP + FN}, \quad precision = \frac{TP}{TP + FP}, \quad FPR = \frac{FP}{FP + TN}$$

*Recall* – מספר האנשים שסיווגנו כ-*Positives* מתוך כל קבוצת האנשים שה-*label* שלהם הוא אכן *Positive*.

*Precision* – מספר הסיווגים הנכונים שסיווגנו כ-*Positives* מתוך כל קבוצת האנשים שסיווגנו כ-*Positives*.

*FPR* – קבוצת האנשים שסיווגנו *Positive* מתוך קבוצת כל האנשים שה-*label* האמיתי שלהם הוא *Negative*.

ב. דוגמא טובה תהייה מחלה סופנית – *recall* גבוה אומר שאנחנו שמים דגש על לאבחן כל חולה שאכן חולה במחלה, כמאומת, בשלב מוקדם ככל האפשר.

אם ה-*precision* כתוצאה מכך יורד (דבר שעלול לקרות אם אנחנו מחמירים בסיווג לכיוון *Positive*) אז הנזק יהיה הרבה פחות נוראי כי בעצם יהיו יותר אנשים שיחשבו שהם חולים, ואחר כך יתברר שהם לא.

ג. סקר שוק לגבי מכירה של מוצר ללקוחות. אנו נרצה לייצר את המוצר תוך כדי התחשבות בכמות האנשים שאכן ירצו לקנות אותו, על מנת לא לצאת בהפסד בעלות הייצור.

במצב זה נרצה *Precision* גבוה, היות וזה אומר שנוכל לייצר כמות מדוייקת של מוצרים לפי ה-*Precision*. בעקבות כך, כנראה, ה-*recall* שלנו יירד, וזה אומר שנפספס כמה קונים פוטנציאליים בסקר, מתוך קבוצת כל הקונים שאכן היו קונים את המוצר – דבר שלא יעלה לנו ביותר מידי כסף על עלות הייצור.

ד.

$$P_w(y = 1|x) = \frac{e^{w^T x}}{1 + e^{w^T x}} = \frac{e^{-0.3*1 - 0.5x_1 + 0.5x_2}}{1 + e^{-0.3*1 - 0.5x_1 + 0.5x_2}}$$

$$P_w(y = 1|x_1) = \frac{e^{-3.3}}{1 + e^{-3.3}} \approx 0.0355, \quad P_w(y = 1|x_2) = \frac{e^{0.7}}{1 + e^{0.7}} \approx 0.6682$$

$$P_w(y = 1|x_3) = \frac{e^{-7.3}}{1 + e^{-7.3}} \approx 6 * 10^{-4}, \quad P_w(y = 1|x_4) = \frac{e^{-1.3}}{1 + e^{-1.3}} \approx 0.214$$

$$P_w(y = 1|x_5) = \frac{e^{-8.8}}{1 + e^{-8.8}} \approx 1.5 * 10^{-4}$$

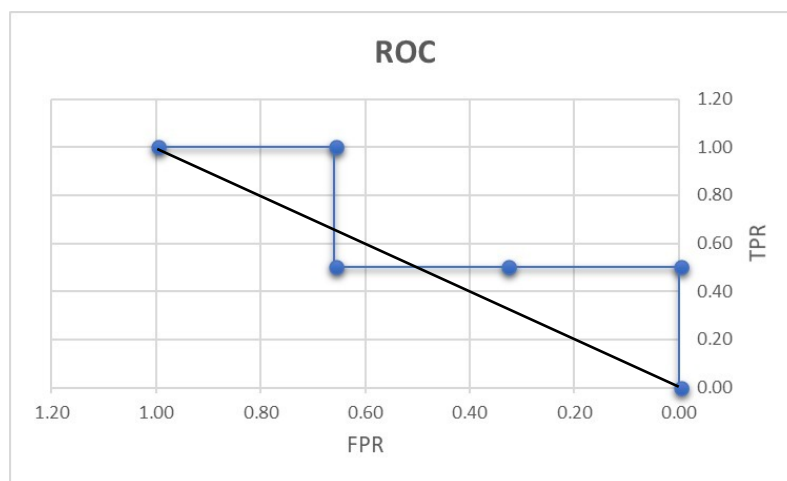
ה.

Threshold	x1	x2	x3	x4	x5
$1.5 * 10^{-5}$	1	1	1	1	1
$1.5 * 10^{-3}$	1	1	1	1	0
$6 * 10^{-3}$	1	1	0	1	0
0.04	0	1	0	1	0
0.3	0	1	0	0	0
0.7	0	0	0	0	0
lable	0	1	1	0	0

Threshold	TP	TN	FP	FN	TPR	FPR
$1.5 * 10^{-5}$	2	0	3	0	1.00	1.00
$1.5 * 10^{-3}$	2	1	2	0	1.00	0.66
$6 * 10^{-3}$	1	1	2	1	0.50	0.66
0.04	1	2	1	1	0.50	0.33
0.3	1	3	0	1	0.50	0.00
0.7	0	3	0	2	0.00	0.00

הגרף שהתקבל:



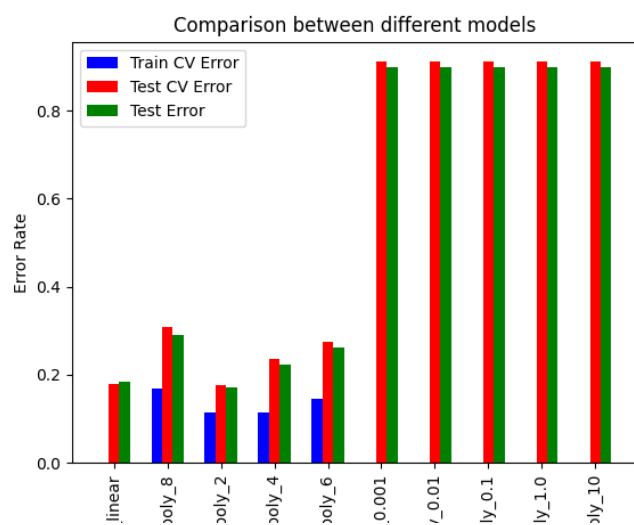










הקו השחור הוא המודל האקראי.

ניתן לראות כי עבור ערכי  $Threshold \in [0,0.5]$  השגיאה של המודל שלנו תהייה נמוכה יותר. ניתן לראות כי אנו נקבל  $TPR$  גבוה יותר עבור כל ערך  $FPR$  נתון. ולכן נוכל להגיד שהמודל שלנו טוב יותר.

### שאלה 3:

א. הקוד כולו מצורף בסוף המסמך.

ב. התמונות שהתקבלו:



ג. הקוד מצורף בסוף המסמך.

ד. הגרף שהתקבל:

ניתן לראות כי המודל שהיה הכי מוצלח לפי שיטת ה- $CV$  הינו המודל  $SVM\_Linear$  היות ושגיאת האימון היא 0 ושגיאת הולידציה הכי נמוכה. למרות זאת, שגיאת הולידציה של  $SVM\_poly\_2$  זהה גם היא לשגיאת הולידציה שקיבלנו ב  $SVM\_Linear$ .

שגיאת המבחן הנמוכה ביותר ללא  $CV$  התקבלה עבור  $SVM\_poly\_2$ , ולכן נוכל לומר ששיטת ה- $CV$  אכן איתרה את המודל בעל שגיאת המבחן הנמוכה ביותר (או לפחות, אחד מהם).

```

1 import numpy as np
2 from sklearn.datasets import fetch_openml
3 from sklearn.svm import SVC
4 from sklearn.model_selection import train_test_split
5 import matplotlib.pyplot as plt
6
7
8 def cross_validation_error(X, y, model, folds):
9     samples_sub_arrays = np.array_split(X, folds)
10    labels_sub_arrays = np.array_split(y, folds)
11    error_k_train = []
12    error_k_test = []
13    for k in range(folds):
14        # Split the array into sub-arrays of approximately the same size.
15        # Choose the k-th array as the test array, and combine all others as
the training set.
16        X_test = samples_sub_arrays.pop(k)
17        y_test = labels_sub_arrays.pop(k)
18        X_train = np.vstack(samples_sub_arrays)
19        y_train = np.concatenate(labels_sub_arrays)
20        model.fit(X_train, y_train)
21        # Calculate error on training set
22        y_pred_train = model.predict(X_train)
23        error_count = 0
24        for i in range(len(y_train)):
25            if y_pred_train[i] != y_train[i]:
26                error_count += 1
27        error_k_train.append(error_count / len(y_train))
28        # Calculate error on test set
29        y_pred_test = model.predict(X_test)
30        error_count = 0
31        for i in range(len(y_pred_test)):
32            if y_pred_test[i] != y_test[i]:
33                error_count += 1
34        error_k_test.append(error_count / len(y_test))
35        # Return the chosen sub-arrays back with all training points
36        samples_sub_arrays.insert(k, X_test)
37        labels_sub_arrays.insert(k, y_test)
38    avg_error = (sum(error_k_train)/folds, sum(error_k_test)/folds)
39    return avg_error
40
41
42 def svm_results(X_train, y_train, X_test, y_test):
43     error_results = {}
44     error = 0
45     model = SVC(kernel='linear')
46     model.fit(X_train, y_train)
47     y_pred = model.predict(X_test)
48     for i in range(len(y_test)):
49         if y_test[i] != y_pred[i]:
50             error = error + 1
51     test_error = error/len(y_test)
52     CV_error = cross_validation_error(X_train, y_train, model, 4)
53     error_results['SVM_linear'] = (CV_error[0], CV_error[1], test_error)
54     d_list = {2, 4, 6, 8}
55     for d in d_list:
56         model = SVC(kernel='poly', degree=d)
57         error = 0
58         model.fit(X_train, y_train)
59         y_pred = model.predict(X_test)

```



```

60         for i in range(len(y_test)):
61             if y_test[i] != y_pred[i]:
62                 error = error + 1
63             test_error = error/len(y_test)
64             CV_error = cross_validation_error(X_train, y_train, model, 4)
65             error_results[f'SVM_poly_{d}'] = (CV_error[0], CV_error[1], test_error
66         )
67         rbf_values = [0.001, 0.01, 0.1, 1.0, 10]
68         for val in rbf_values:
69             model = SVC(kernel='rbf', gamma=val)
70             error = 0
71             model.fit(X_train, y_train)
72             y_pred = model.predict(X_test)
73             for i in range(len(y_test)):
74                 if y_test[i] != y_pred[i]:
75                     error = error + 1
76             test_error = error / len(y_test)
77             CV_error = cross_validation_error(X_train, y_train, model, 4)
78             error_results[f'SVM_poly_{val}'] = (CV_error[0], CV_error[1],
79             test_error)
80         return error_results
81
82 def fetch_mnist():
83     # Download MNIST dataset
84     X, y = fetch_openml('Fashion-MNIST', version=1, return_X_y=True)
85     X = X.to_numpy()
86     y = y.to_numpy()
87
88     # Randomly sample 7000 images
89     np.random.seed(2)
90     indices = np.random.choice(len(X), 7000, replace=False)
91     X, y = X[indices], y[indices]
92     return X, y
93
94 def main():
95     X, y = fetch_mnist()
96     print(X.shape, y.shape)
97     idx2class = {'0': 'T-shirt/top', '1': 'Trouser', '2': 'Pullover', '3': '
Dress', '4': 'Coat', '5': 'Sandal',
98                 '6': 'Shirt', '7': 'Sneaker', '8': 'Bag', '9': 'Ankle'}
99     for i in range(10):
100         image = X[i].reshape(28, 28)
101         s = idx2class[y[i]]
102         plt.title(f'{y[i]}, {s}')
103         plt.imshow(image, cmap='binary')
104         plt.show()
105
106     X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.25,
107     random_state=42)
108     error_res = svm_results(X_train, y_train, X_test, y_test)
109
110     train_cv_error = []
111     test_cv_error = []
112     test_error = []
113     labels_names = []
114     index_range = range(len(error_res.keys()))
115     for key in error_res.keys():
116         train_cv_error.append(error_res[key][0])

```

```
116         test_cv_error.append(error_res[key][1])
117         test_error.append(error_res[key][2])
118         labels_names.append(key)
119
120     fig1, ax1 = plt.subplots()
121     ax1.set_xlabel("Model")
122     ax1.set_ylabel("Error Rate")
123     width = 0.2
124     ax1.bar([val - width for val in index_range], train_cv_error, width=width
125             , color='blue', label='Train CV Error')
126     ax1.bar([val for val in index_range], test_cv_error, width=width, color='
127     red', label='Test CV Error')
128     ax1.bar([val + width for val in index_range], test_error, width=width,
129             color='green', label='Test Error')
130     ax1.set_xticks(index_range, labels_names, rotation=90)
131     plt.title("Comparison between different models")
132     plt.gcf().subplots_adjust(bottom=0.3)
133     plt.legend()
134     plt.show()
135
136 if __name__ == '__main__':
137     main()
```